Proyecto Deep Learning: Detección de Imágenes Generadas por IA utilizando CNNs

Camilo Benavides Ramirez, Brayan Santiago Ramirez Silva, Mariana Velásquez Velásquez

***Resumen*—Este trabajo evalúa el desempeño de una Red Neuronal Convolucional (CNN) para clasificar imágenes como reales o generadas por Inteligencia Artificial (IA) utilizando el dataset *CIFAKE*. Se implementó una arquitectura base que incluye bloques convolucionales, reducción de dimensionalidad y regularización para mitigar el sobreajuste. El modelo obtuvo resultados sobresalientes desde la primera iteración, alcanzando una exactitud del 92.87% y un F1-Score macro de 0.93, estableciendo una sólida línea base para futuras optimizaciones en la detección de contenido sintético.**

***Palabras Claves*—Deep Learning, Redes Neuronales Convolucionales, CNN, CIFAKE, Imágenes Sintéticas, Inteligencia Artificial.**

I. Introducción

En la última década, el campo de la Inteligencia Artificial Generativa ha experimentado un avance sin precedentes. Específicamente, los modelos de difusión de texto a imagen (Text-to-Image), como Stable Diffusion, Midjourney, DALL-E, o NanoBanana han democratizado la creación de contenido visual hiperrealista a tal punto de que es realmente difícil diferenciar la realidad de artefactos generados por la IA. Aunque esto representa una revolución para el arte digital y el diseño, también ha introducido vectores de riesgo críticos en la sociedad moderna.

La proliferación de imágenes sintéticas (comúnmente asociadas a deepfakes o contenido fabricado) dificulta la distinción entre fotografías capturadas por sensores ópticos reales y matrices de píxeles generadas estadísticamente. Esto tiene implicaciones directas en múltiples sectores:

- **Ciberseguridad y Verificación de Identidad:** Sistemas que dependen de pruebas de vida (liveness detection) pueden ser vulnerados mediante imágenes generadas.
- **Periodismo e Integridad de la Información:** La propagación de noticias falsas (Fake News) acompañadas de evidencia visual fabricada erosiona la confianza pública.
- **Redes Sociales y Moderación de Contenido:** Las plataformas requieren mecanismos automatizados para etiquetar contenido sintético y cumplir con regulaciones emergentes sobre la transparencia de la IA.

Ante este panorama, el desarrollo de sistemas de Visión Computacional capaces de auditar y clasificar la procedencia de una imagen se ha vuelto una necesidad imperativa.

II. Objetivo del problema

El objetivo principal de este proyecto es diseñar, entrenar y evaluar un modelo de aprendizaje profundo basado en Redes Neuronales Convolucionales (CNN) para resolver un problema de clasificación binaria. El sistema toma como entrada una imagen digital y emite una predicción probabilística sobre su naturaleza, clasificándola en una de dos categorías: REAL o FAKE.

Para esta primera iteración, el objetivo específico es establecer un modelo base (Baseline) funcional. Esto implica resolver el ciclo completo de vida del dato: desde la ingesta y normalización de los tensores, el diseño de una arquitectura convolucional secuencial sencilla, hasta el entrenamiento y la evaluación del modelo generando métricas predictivas viables.

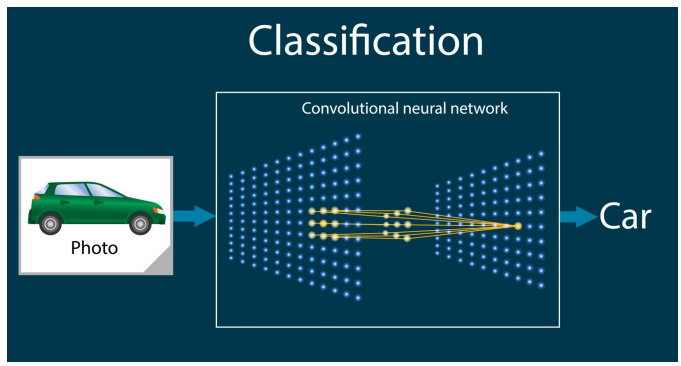

Fig. 1. Esquema general del problema de clasificación binaria.

III. Descripción del Dataset y Requerimientos

A. Origen y Naturaleza de los Datos

El dataset es una combinación de dos fuentes distintas pero dimensionalmente equivalentes:

- **Clase REAL (0):** Compuesta por imágenes del clásico dataset CIFAR-10, recopilado por Krizhevsky & Hinton. Representan fotografías genuinas de diversos objetos y animales.
- **Clase FAKE (1):** Compuesta por imágenes generadas sintéticamente utilizando el modelo Stable Diffusion versión 1.4, introducidas por Bird y Lotfi (2024), diseñadas para emular las categorías visuales de CIFAR-10.

B. Tamaño y Distribución

El corpus total consta de 120,000 imágenes a color en formato RGB, con una resolución estandarizada de 32×32 píxeles. El dataset presenta un balance de clases perfecto (50/50), estructurado de la siguiente manera:

- **Conjunto de Entrenamiento:** 100,000 imágenes (50,000 reales y 50,000 sintéticas).
- **Conjunto de Pruebas (Test/Validación):** 20,000 imágenes (10,000 reales y 10,000 sintéticas).

Este balance es crucial, ya que evita sesgos algorítmicos durante el ajuste de pesos de la red neuronal y simplifica la interpretación de las métricas de exactitud.

C. Requerimientos Computacionales

Gracias a la baja dimensionalidad topológica de las imágenes ($32 \times 32 \times 3$), el peso total del dataset en disco es de aproximadamente 200 MB. Esto reduce drásticamente los requerimientos de memoria RAM. Durante la primera iteración, el modelo demostró ser computacionalmente ligero: el entrenamiento en CPU requirió aproximadamente 287 segundos para la primera época (fase de inicialización y caché) y se estabilizó en un promedio de 43 a 45 segundos por época para las 9 épocas restantes. El tiempo total de entrenamiento para 10 épocas fue inferior a 15 minutos, lo que confirma la viabilidad del proyecto bajo recursos de hardware estándar.

IV. Arquitectura del Modelo (Primera Iteración)

Para esta etapa inicial, se implementó una Red Neuronal Convolucional (CNN) secuencial a través de la API Keras de TensorFlow. La arquitectura fue diseñada para extraer jerárquicamente características espaciales de las imágenes:

- **Bloques Convolucionales:** Se utilizaron múltiples capas Conv2D para aplicar filtros que detectan patrones locales (bordes, texturas), características que suelen diferenciar las imágenes reales del "ruido" residual dejado por los modelos de difusión.
- **Reducción de Dimensionalidad:** Capas de MaxPooling2D para reducir la resolución espacial de los mapas de características, minimizando la carga computacional y logrando invariancia a la traslación.
- **Regularización:** Se introdujo una capa de Dropout con una tasa del 0.5 (50%) antes de las capas densas. Esto apaga neuronas aleatoriamente durante el entrenamiento, siendo una técnica fundamental para mitigar el sobreajuste (Overfitting) en un dataset de 100,000 imágenes.
- **Clasificador Final:** Una capa Dense totalmente conectada que reduce la información a una única salida, utilizando una función de activación óptima para clasificación binaria, apoyada por la función de pérdida *binary_crossentropy*.

V. Métricas de desempeño y herramientas de evaluación

Para evaluar el comportamiento del modelo de clasificación binaria propuesto, se definieron métricas que permiten medir su rendimiento. Dado que el problema consiste en clasificar imágenes en dos categorías, REAL y FAKE, y que el conjunto de datos se encuentra balanceado, la evaluación no debe limitarse a una sola medida, sino considerar diferentes indicadores complementarios: Se consideran los siguientes términos: VP (verdaderos positivos), VN (verdaderos negativos), FP (falsos positivos) y FN (falsos negativos).

- **Exactitud (Accuracy):** Mide la proporción total de predicciones correctas realizadas por el modelo respecto al total de muestras evaluadas. Dado que el dataset presenta un balance de clases 50/50, esta métrica resulta adecuada para ofrecer una visión global del desempeño del clasificador.

$$Accuracy = \frac{VP + VN}{VP + VN + FP + FN} \tag{1}$$

- **Precisión (Precision):** Evalúa qué proporción de las instancias predichas como positivas realmente pertenece a la clase positiva. En este contexto, permite medir qué tan confiable es la predicción del modelo cuando identifica una imagen como perteneciente a una clase determinada.

$$Precision = \frac{VP}{VP + FP} \tag{2}$$

- **Exhaustividad (Recall):** Mide la capacidad del modelo para identificar correctamente los casos positivos reales. Esta métrica es especialmente relevante para la clase FAKE, ya que permite cuantificar qué porcentaje de imágenes generadas por IA logra detectar el sistema.

$$Recall = \frac{VP}{VP + FN} \tag{3}$$

- **F1-Score:** Corresponde a la media armónica entre la precisión y el recall, por lo que resume en un solo valor el equilibrio entre ambas métricas. En este proyecto se emplea el F1-Score macro, que promedia el F1 de cada clase y resulta útil para evaluar de manera equilibrada el rendimiento global del modelo.

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} \tag{4}$$

En su versión macro:

$$F1_{macro} = \frac{F1_{REAL} + F1_{FAKE}}{2} \tag{5}$$

- **Pérdida de clasificación (Binary Crossentropy):** Mide la capacidad del modelo para identificar correctamente los casos positivos reales. Esta métrica es especialmente relevante para la clase FAKE, ya que permite cuantificar qué porcentaje de imágenes generadas por IA logra detectar el sistema.

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^{N} \left[y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i) \right] \tag{6}$$

donde y_i representa la etiqueta real de la muestra i, y $\hat{y}_i$ la probabilidad predicha por el modelo.

- **Matriz de confusión:** Finalmente, se emplea la matriz de confusión como herramienta de análisis detallado del comportamiento del clasificador. Esta permite identificar de forma explícita la cantidad de verdaderos positivos, verdaderos negativos, falsos positivos y falsos negativos, facilitando la interpretación de los errores cometidos por el modelo y su impacto en un escenario de aplicación real.

$$\text{Matriz de Confusión} = \begin{bmatrix} VP & FN \\ FP & VN \end{bmatrix} \tag{7}$$

En este trabajo, considerando la clase positiva como *FAKE*, la matriz puede interpretarse como:

$$\begin{bmatrix} \text{FAKE predicha como FAKE} & \text{FAKE predicha como REAL} \\ \text{REAL predicha como FAKE} & \text{REAL predicha como REAL} \end{bmatrix} \tag{8}$$

VI. Resultados Obtenidos

A. Resultados Preliminares y Métricas de Desempeño

Tras compilar el modelo con el optimizador Adam y entrenarlo durante 10 épocas, se obtuvieron resultados predictivos altamente satisfactorios, logrando la convergencia de la función de pérdida desde 0.3467 hasta 0.1057 en la fase de entrenamiento.

B. Evaluación de Machine Learning

Sobre el conjunto de pruebas de 20,000 imágenes, el modelo alcanzó una Exactitud (Accuracy) del 92.87% y una pérdida de validación de 0.2324. Dado el balanceo perfecto del dataset, el Accuracy es una métrica sólida que indica que el modelo predice correctamente más de 9 de cada 10 imágenes.

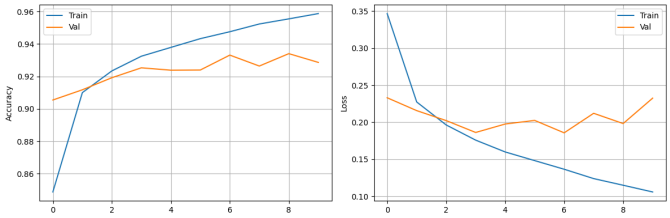

Fig. 2. Curvas de aprendizaje del modelo mostrando la evolución de la pérdida y la exactitud.

C. Evaluación de Negocio y Clasificación

Desde la perspectiva de la aplicación real, se analizó el Reporte de Clasificación (Classification Report):

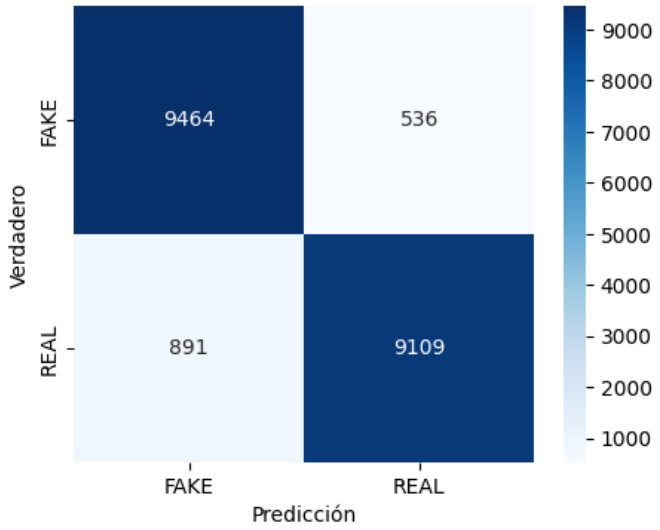

Fig. 3. Matriz de confusión obtenida tras la evaluación del conjunto de pruebas.

- **Para la clase FAKE:** Se obtuvo un Recall (Exhaustividad) de 0.95, lo que significa que el modelo es sumamente hábil detectando imágenes generadas por IA, dejando escapar apenas un 5% de ellas (Falsos Negativos).
- **Para la clase REAL:** Se obtuvo un Precision (Precisión) de 0.94, garantizando que cuando el modelo etiqueta una imagen como "REAL", tiene un alto grado de certeza, minimizando el riesgo de penalizar o censurar contenido genuino creado por usuarios (Falsos Positivos).

El F1-Score Macro global fue de 0.93, demostrando un equilibrio excepcional entre ambas clases.

VII. Revisión de Literatura

La detección de imágenes generadas por inteligencia artificial ha sido abordada recientemente desde distintos enfoques, incluyendo clasificadores supervisados, detectores con capacidad de generalización entre generadores y métodos orientados a modelos de difusión. En la literatura, la evaluación suele apoyarse en métricas como *accuracy*, *precision*, *recall*, *F1-score*, *average precision* (AP) y *AUC-ROC*. La Tabla I resume algunos trabajos representativos y las métricas empleadas en cada caso.

Tabla I. Resumen de trabajos relacionados en detección de imágenes generadas por IA

Trabajo	**Aporte principal**	**Métricas usadas**
Bird y Lotfi [2]	Proponen el dataset *CIFAKE* y abordan el problema como una clasificación binaria entre imágenes reales y sintéticas.	Accuracy, Precision, Recall, F1-score
Wang et al. [3]	Estudian la detección de imágenes generadas por CNN y analizan la capacidad de generalización del detector hacia generadores no vistos.	AP, Accuracy
Ojha et al. [4]	Evalúan detectores con énfasis en la generalización entre distintas familias de modelos generativos.	AP, Accuracy
Cazenavette et al. [5]	Proponen *FakeInversion* para detectar imágenes generadas por modelos de texto a imagen no vistos durante el entrenamiento.	AUC-ROC, AP, Accuracy

References

[1] J. J. Bird and A. Lotfi, "CIFAKE: Real and AI-Generated Synthetic Images," *Kaggle*, 2024. [Online]. Available: https://www.kaggle.com/datasets/birdy654/cifake-real-and-ai-generated-synthetic-images

[2] J. J. Bird and A. Lotfi, "CIFAKE: Image Classification and Explainable Identification of AI-Generated Synthetic Images," *arXiv preprint arXiv:2303.14126*, 2023. [Online]. Available: https://www.researchgate.net/publication/369541020_CIFAKE_Image_Classification_and_Explainable_Identification_of_AI-Generated_Synthetic_Images

[3] S.-Y. Wang, O. Wang, R. Zhang, A. Owens, and A. A. Efros, "CNN-Generated Images Are Surprisingly Easy to Spot... for Now," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2020, pp. 8695–8704. [Online]. Available: https://www.researchgate.net/publication/343456306_CNN-Generated_Images_Are_Surprisingly_Easy_to_Spot_for_Now

[4] U. Ojha, Y. Li, and Y. J. Lee, "Towards Universal Fake Image Detectors That Generalize Across Generative Models," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2023, pp. 24480–24489. [Online]. Available: https://www.researchgate.net/publication/368664365_Towards_Universal_Fake_Image_Detectors_that_Generalize_Across_Generative_Models

[5] G. Cazenavette, A. Sud, T. Leung, and B. Usman, "FakeInversion: Learning to Detect Images from Unseen Text-to-Image Models by Inverting Stable Diffusion," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2024, pp. 10759–10769. [Online]. Available: https://www.researchgate.net/publication/381404176_FakeInversion_Learning_to_Detect_Images_from_Unseen_Text-to-Image_Models_by_Inverting_Stable_Diffusion